



# Minimização de Função: Função Ackley

Eduardo Barreto  
Daniel Carriço  
Juliana Damurie  
Matheus Casa Nova



# Configurações & Algoritmos

- Representação (genótipo): array de 30 números reais
- Probabilidade de Recombinação: 90%
- Probabilidade de Mutação: 5%
- Tamanho da população: 100
- Inicialização: aleatória (sem repetição)
- Seleção: Melhores pais aleatórios com elitismo
- Cruzamento: Crossover modificado
- Mutação: Não Uniforme modificada
- Critério de parada: 10000 gerações ou fitness > 0.999
- Arredondamento dos números reais para 7 casas decimais



# Seleção: Melhores pais aleatórios com elitismo

- Seleciona 5 indivíduos aleatoriamente;
- escolhe os 2 indivíduos com maior fitness;
- cruza os dois indivíduos escolhidos; e
  - se o filho gerado tiver maior fitness que o pior da população, ele o substitui;
  - caso contrário, o filho é descartado.



# Cruzamento: Crossover modificado

- Tendo os pais:
  - $paia = [x1, x2, \dots, xn]$
  - $paib = [y1, y2, \dots, yn]$
- seleciona-se um ponto de corte (pc) aleatório entre 0 e o tamanho do indivíduo:
- seleciona-se um "fator de crossover" (fc) aleatório entre 0 e 1;
- cria-se dois genes resultantes de um crossover comum:
  - $halfa = [x1, x2, \dots, xpc, ypc+1, \dots, yn]$
  - $halfb = [y1, y2, \dots, ypc, xpc+1, \dots, xn]$
- multiplica-se cada gene pelo fator de crossover fc e divide-se por 2:
  - $halfa = halfa * fc * 0.5$
  - $halfb = halfb * fc * 0.5$
- gera-se um filho único como a soma das duas metades:
- $filho = halfa + halfb$



# Mutação: Não Uniforme modificada

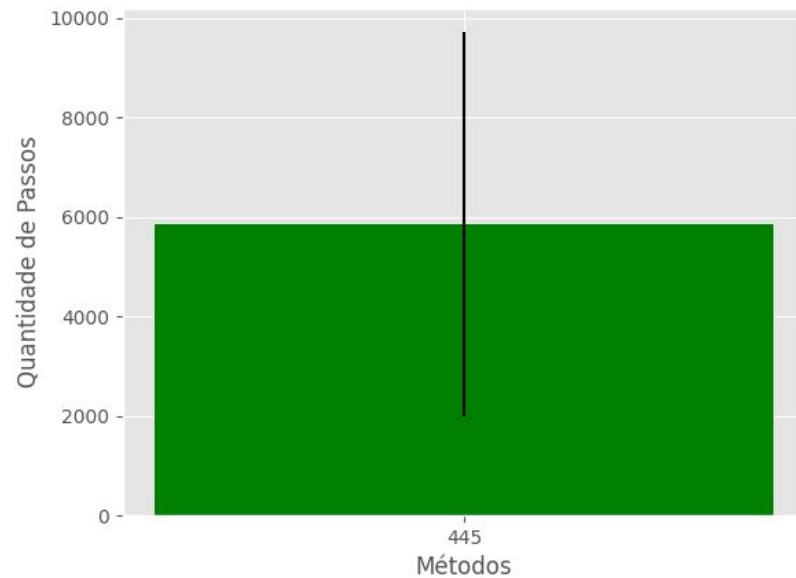
- Tendo o indivíduo:
  - $\text{individuo}_x = [x_1, x_2, \dots, x_n];$
- gera-se um array de mesmo tamanho de floats aleatórios entre 0 e 1:
  - $z = [z_1, z_2, \dots, z_n]$
- soma-se os dois arrays de forma que o novo indivíduo resulte em:
  - $\text{indivíduoNovo}_x = \text{individuo}_x + z = [x_1 + z_1, x_2 + z_2, \dots, x_n + z_n]$




# Método de Avaliação de Algoritmo

- 10000 repetições de cada algoritmo (cada repetição com a mesma população)
- Mantivemos o tamanho da população e a representação
- Média de:
  - Quantidade de Passos (gerações) até chegar a resposta desejada
  - Média de Fitness dos indivíduos por geração
  - Média de Fitness dos melhores indivíduos por geração
  - Tempo de execução até achar a resposta
  - Soma de fitness dos indivíduos

# Resultados




# Resultados







# Resultados



# Resultados



# Resultados





# Considerações Finais

- Outros algoritmos foram testados, mas esse foi o que trouxe melhores resultados. Justificativa:
  - Passos pequenos na exploração;
  - Mantém genes bons, mas ainda assim os varia um pouco, o que faz com que evite mínimos locais;
  - Mutações com baixa probabilidade e pouca variação, evitando a destruição do indivíduo
  - Só mantém o filho se ele for bom o suficiente, descartando caso tenha sido um filho ruim (evita levar a população toda para algum lugar não promissor)



# Considerações Finais

- Os outros algoritmos, descritos no relatório, são:
  - Seleção:
    - Melhores pais / piores indivíduos
    - Matar metade da população
    - Sobrevivência dos mais fortes
    - **Melhores pais aleatórios com elitismo\***
  - Cruzamento:
    - Cruzamento Discreto
    - Cruzamento Intermediário
    - Cruzamento BLX-alpha
    - **Crossover modificado\***
  - Mutação:
    - Uniforme
    - Não Uniforme
    - Gaussiana
    - BLX-alpha
    - **Não Uniforme Modificada\***

A configuração escolhida foi retirada de um artigo:

“Algoritmo genético modificado para minimização de funções”.

Joelan A. L. Santos, Márcio M. da Silva, José de A. da S. Júnior, André C. A. Firmo e Tiago A. E. Ferreira.

Publicado no 8º Encontro Regional de Matemática Aplicada e Computacional;



## Breve visualização de resultados

